

Asignación 1

Jorge Silva 2160411 - José Sosa 2241670

Universidad Industrial de Santander

Calle 9#27/Bucaramanga/Santander

26/09/2025

Índice

1. Introducción	2
2. Metodología	3
2.1. Primer tratamiento de datos (entrega y normalización)	3
2.2. Distancia Euclidiana	3
2.3. Calibración lineal y alcance de validez	5
2.4. Validación por división mitad-mitad	6
2.5. Tamaño mínimo de entrenamiento y alcance máximo	7
3. Resultados y análisis	8
3.1. Distancia Euclideana	8
3.2. Calibración lineal y alcance de validez	11
3.3. Validación por división mitad-mitad	14
3.4. Tamaño mínimo de entrenamiento y alcance máximo	16
4. Conclusiones y Recomendaciones	20
5. Referencias	21

Resumen

Introducción. La creciente proliferación de sensores de bajo costo en aplicaciones de Internet de las Cosas (IoT) requiere métodos robustos de calibración para garantizar la precisión de las mediciones ambientales. Este trabajo aborda el problema de calibrar sensores de material particulado PM2.5 mediante el método de mínimos cuadrados.

Metodología. Implementamos un pipeline completo de procesamiento que incluye: (i) normalización y alineación temporal de series de datos de estaciones de referencia y bajo costo; (ii) cálculo de distancias euclidianas para ventanas móviles de 3 a 72 horas; (iii) ajuste lineal forzado al origen $y = \alpha x$ mediante mínimos cuadrados; (iv) validación cruzada por división mitad-mitad; y (v) determinación del tamaño mínimo de entrenamiento para predicciones válidas.

Resultados. El análisis reveló que ventanas de 72 horas minimizan la distancia euclidiana, con coeficientes de calibración α entre 0,64 (Acualago) y 0,92 (Pilar). Los modelos alcanzaron $R_0^2 > 0,96$ y coberturas de validez superiores al 93 % bajo la tolerancia máx(5 $\mu\text{g}/\text{m}^3$, 20 % y). La validación predictiva mostró excelente desempeño en Caldas y Normal (100 % cobertura), mientras que se identificaron límites operativos para Girón y Pilar.

Conclusiones. Demostramos que el método de mínimos cuadrados proporciona una calibración efectiva de sensores de bajo costo, estableciendo rangos de validez precisos y requisitos mínimos de datos para predicciones confiables. Estos hallazgos tienen implicaciones significativas para el despliegue masivo de redes de monitoreo ambiental asequibles.

Palabras clave: Mínimos cuadrados, calibración de sensores, PM2.5, IoT, validación predictiva.

1. Introducción

La revolución de la Internet de las Cosas (IoT, por sus siglas en inglés) ha democratizado el acceso a tecnologías de monitoreo ambiental, permitiendo el despliegue masivo de sensores de bajo costo para la medición de contaminantes atmosféricos como el material particulado PM2.5. Sin embargo, la asequibilidad de estos dispositivos frecuentemente compromete su precisión, generando un desafío crítico para la confiabilidad de las mediciones en aplicaciones de salud pública y vigilancia ambiental [7, 6].

El problema fundamental radica en la calibración de estos sensores, que presentan derivas temporales y sesgos sistemáticos respecto a estaciones de referencia. Métodos tradicionales de calibración requieren equipos costosos y procedimientos complejos, limitando su escalabilidad. Ante esta problemática, los métodos estadísticos basados en mínimos cuadrados emergen como una solución elegante y eficiente para establecer relaciones de calibración robustas [1, 2].

En este contexto, el presente trabajo aborda el desafío de calibrar sensores de PM2.5 mediante la aplicación sistemática del método de mínimos cuadrados. A diferencia de aproximaciones previas, nuestro enfoque incorpora un análisis exhaustivo de ventanas temporales óptimas, validación predictiva rigurosa y la determinación de tamaños mínimos de entrenamiento, proporcionando un marco metodológico completo para implementaciones prácticas.

Los principales aportes de esta investigación incluyen: (i) la identificación de ventanas óptimas de suavización temporal para minimizar discrepancias entre sensores; (ii) el establecimiento de coeficientes de calibración específicos para diferentes estaciones de referencia; (iii) la validación de la capacidad predictiva mediante división mitad-mitad; y (iv) la determinación de requisitos mínimos de datos para calibraciones confiables.

Este artículo se estructura de la siguiente manera: en la Sección 2 presentamos la metodología empleada, detallando el procesamiento de datos, el cálculo de distancias euclidianas y la implementación del ajuste por mínimos cuadrados. En la Sección 3 analizamos los resultados obtenidos para diferentes configuraciones y estaciones. Finalizamos con las conclusiones y recomendaciones en la Sección 4, donde discutimos las implicaciones prácticas de nuestros hallazgos.

2. Metodología

2.1. Primer tratamiento de datos (entrega y normalización)

Origen y formato de entrega. Las estaciones de referencia fueron provistas por la autoridad ambiental en archivos **Excel/CSV** con campos de *fecha*, *hora* y *PM2.5* (en $\mu\text{g}/\text{m}^3$). La estación de bajo costo **Colegio Normal** se recibió en **siete** archivos en el mismo esquema de columnas (un conjunto por período). El objetivo de este primer tratamiento fue *solo* unificar formato y garantizar consistencia de tipos, sin alterar los valores medidos.

Pasos de normalización.

1. **Estandarización de nombres y tipos:** las columnas se normalizaron a $\{\text{Fecha}, \text{Hora}, \text{PM2.5}\}$ y se homogenizó el separador decimal (coma $\rightarrow$ punto cuando aplicó).
2. **Construcción de la marca de tiempo:** se creó el instante $t_k = \text{to_datetime}(\text{Fecha}_k + " " + \text{Hora}_k)$, preservando el orden cronológico y descartando únicamente filas con *timestamp* inválido (NA).
3. **Orden y duplicados exactos:** las tablas se ordenaron por t_k y se eliminaron duplicados estrictos de fila (si existían).
4. **Integración de Colegio Normal:** los **siete** archivos se concatenaron en una sola serie crónica manteniendo el esquema $\{\text{Fecha}, \text{Hora}, \text{PM2.5}\}$.

Criterios y límites. En esta etapa *no* se aplicaron interpolaciones, filtros de picos ni imputaciones; los valores de $\text{PM}_{2.5}$ se conservaron tal cual fueron medidos. El tratamiento posterior de irregularidad temporal (agregación horaria y promedios móviles centrados) se ejecuta en la etapa siguiente.

Productos de salida. Como resultado se generaron archivos CSV *normalizados* por estación, que fueron insumo directo para las etapas de remuestreo horario, suavizado y análisis (secciones metodológicas siguientes).

Códigos. El proceso se implementó en dos scripts: **“Primer Tratamiento AMB”** (depuración y normalización de entrega) y **“Segundo tratamiento”** (remuestreo, suavizado y cálculos subsecuentes). Ambos estarán disponibles en el repositorio *GitHub* asociado a este reporte.

2.2. Distancia Euclidiana

El objetivo fue estimar la distancia entre las mediciones de la estación de bajo costo y las de varias estaciones de referencia, para distintos anchos de ventana del promedio móvil, y escoger el ancho que minimiza la discrepancia o que se ubica en un “codo” de mejora marginal.

Implementación. Todo el procesamiento se implementó en **Python** (pandas, numpy, matplotlib). El código exacto empleado se presenta como Código 1.^{en} los anexos en el GitHub de esta entrega, y reproduce íntegramente: (i) lectura y unificación de fechas/horas; (ii) remuestreo horario; (iii) promedios móviles centrados para $w \in \{3, 6, 12, 24, 48, 72\}$ h con requisito de datos $\geq 50\%$; (iv) cálculo de $\mathcal{D}_w$ y RMSE_w sobre la intersección temporal; y (v) exportación de las figuras.

Datos y preprocesamiento. Se usaron seis archivos CSV (*Fecha*, *Hora*, *PM2.5*). Para cada archivo se construyó un instante temporal

$$t_k = \text{to_datetime}(\text{Fecha}_k, \text{Hora}_k),$$

y se ordenaron las observaciones. Para hacer comparables las series (algunas con irregularidad temporal) se realizaron promedios **por hora** mediante remuestreo:

$$x^{(\cdot)}(t) = \frac{1}{|\mathcal{I}_t|} \sum_{k \in \mathcal{I}_t} \text{PM}_{2,5}(t_k), \quad t \in \text{horas},$$

donde $\mathcal{I}_t$ indexa los datos que caen en la hora t . Se designó como *bajo costo* a la estación `ColegioNormal_2018-11_a_` y como *referencia* a cada una de: Acualago, Caldas, Girón, Normal y Pilar.

Promedios móviles locales. Para un ancho de ventana w (en horas) se calcularon promedios móviles centrados, tanto en la referencia como en el bajo costo:

$$m_w^{(\text{ref})}(t) = \frac{1}{|W_w(t)|} \sum_{u \in W_w(t)} x^{(\text{ref})}(u), \quad m_w^{(\text{low})}(t) = \frac{1}{|W_w(t)|} \sum_{u \in W_w(t)} x^{(\text{low})}(u),$$

con $W_w(t) = \{u : |u - t| \leq w/2\}$ y requerimiento de datos mínimos equivalente a $\geq 50\%$ de la ventana para evitar promedios demasiado malos.

Alineación y métrica. Se construyó el conjunto de tiempos de intersección

$$T_w = \{t : m_w^{(\text{ref})}(t) \text{ y } m_w^{(\text{low})}(t) \text{ están definidos}\},$$

y se definió la distancia euclídea

$$\mathcal{D}_w = \left(\sum_{t \in T_w} [m_w^{(\text{ref})}(t) - m_w^{(\text{low})}(t)]^2 \right)^{1/2},$$

junto con el *error cuadrático medio* (RMSE) normalizado por el número de puntos válidos:

$$\text{RMSE}_w = \frac{\mathcal{D}_w}{\sqrt{|T_w|}}.$$

Barrido de ventanas. Se evaluaron $w \in \{3, 6, 12, 24, 48, 72\}$ h para cada estación de referencia. El criterio principal fue minimizar $\mathcal{D}_w$ (o RMSE_w); adicionalmente, se identificó un “*codo*” como el primer w donde la mejora relativa de RMSE al pasar al siguiente w cae por debajo del 3 %.

2.3. Calibración lineal y alcance de validez

El objetivo fue calibrar las mediciones de la estación de bajo costo contra cada estación de referencia mediante un **ajuste lineal forzado al origen** sobre promedios móviles centrados de $w = 72$ h, y determinar el *alcance de validez* del modelo a partir de una tolerancia predefinida.

Implementación. Todo el procesamiento se implementó en Python (`pandas`, `numpy`, `matplotlib`). El *código exacto* empleado se presenta como **Código 2** en los anexos (en el repositorio de esta entrega) y reproduce íntegramente: (i) lectura y remuestreo **por hora**; (ii) cálculo de promedios móviles centrados de 72 h con requisito de datos ≥ 50 %; (iii) emparejamiento temporal referencia–bajo costo; (iv) ajuste lineal $y = \alpha x$ *sin intercepto*; (v) evaluación de residuales y tolerancias; y (vi) exportación de la tabla y de las figuras de dispersión, residuales e histograma.

Construcción de pares comparables. Sean x_t y y_t los promedios móviles centrados de 72 h para el bajo costo y la referencia, respectivamente, evaluados en los mismos centros temporales ξ_j . Definimos el conjunto de intersección

$$T = \{t : x_t \text{ y } y_t \text{ están definidos}\},$$

sobre el cual se realiza el ajuste y la evaluación del modelo.

Modelo y estimador. Se ajustó el modelo lineal *forzado al origen*

$$y_t = \alpha x_t, \quad t \in T,$$

cuyo estimador de mínimos cuadrados es

$$\hat{\alpha} = \arg \min_{\alpha} \sum_{t \in T} (y_t - \alpha x_t)^2 = \frac{\sum_{t \in T} x_t y_t}{\sum_{t \in T} x_t^2}.$$

Con residuales $r_t = y_t - \hat{\alpha} x_t$ y $\text{SSE} = \sum r_t^2$, el error estándar de $\hat{\alpha}$ (modelo sin intercepto) se estimó como

$$\hat{\sigma}^2 = \frac{\text{SSE}}{|T| - 1}, \quad \text{Var}(\hat{\alpha}) = \frac{\hat{\sigma}^2}{\sum_{t \in T} x_t^2}, \quad \text{EE}(\hat{\alpha}) = \sqrt{\text{Var}(\hat{\alpha})},$$

y el intervalo de confianza del 95 % como $\hat{\alpha} \pm 1,96 \text{EE}(\hat{\alpha})$.

Bondad de ajuste. Se reportó el coeficiente de determinación del modelo sin intercepto

$$R_0^2 = 1 - \frac{\text{SSE}}{\sum_{t \in T} y_t^2}.$$

Tolerancia y alcance de validez. El modelo se considera *válido* en t cuando el residuo cumple

$$|r_t| \leq \tau_t, \quad \tau_t = \max(5 \mu\text{g}/\text{m}^3, 0,20 y_t).$$

Del subconjunto válido se extrajeron: (i) la **cobertura** (% de observaciones válidas), (ii) el **rango** de x_t donde el modelo es válido $[x_{\min}, x_{\max}]$, y (iii) el **bloque válido continuo más largo** (en horas) para evaluar estabilidad temporal.

2.4. Validación por división mitad–mitad

El objetivo fue evaluar la **capacidad predictiva** del modelo lineal calibrado cuando se entrena con la *primera mitad temporal* de datos y se valida en la *segunda mitad*. Con ello se determina el *alcance para realizar predicciones dentro de la tolerancia*.

Implementación. Todo el procesamiento se implementó en Python (`pandas`, `numpy`, `matplotlib`). El **código exacto** utilizado se presenta como **Código 3** en los anexos (repositorio de esta entrega) y reproduce: (i) construcción de pares comparables, (ii) división cronológica mitad–mitad, (iii) ajuste del modelo forzado al origen en entrenamiento, (iv) predicción sobre prueba, (v) cálculo de métricas (RMSE, R_0^2) y (vi) evaluación de tolerancias, rangos y bloques válidos, además de la exportación de tabla y figuras de prueba.

Datos, remuestreo y promedios. Como en las secciones previas, a partir de los CSV se construyeron promedios por hora y promedios móviles **centrados** de $w = 72$ h para la estación de bajo costo (x_t) y cada referencia (y_t), exigiendo al menos $\geq 50\%$ de datos en la ventana. Se definió el conjunto de tiempos comunes

$$T = \{t : x_t \text{ y } y_t \text{ están definidos}\} = \{t_1, \dots, t_n\}, \quad t_1 < \dots < t_n.$$

División entrenamiento–prueba. Sea $m = \lfloor n/2 \rfloor$. La **mitad de entrenamiento** y la **mitad de prueba** quedaron definidas como

$$T_{\text{train}} = \{t_1, \dots, t_m\}, \quad T_{\text{test}} = \{t_{m+1}, \dots, t_n\}.$$

Modelo y ajuste en entrenamiento. Se ajustó el modelo lineal *forzado al origen*

$$y_t = \alpha x_t, \quad t \in T_{\text{train}},$$

cuyo estimador de mínimos cuadrados es

$$\hat{\alpha} = \frac{\sum_{t \in T_{\text{train}}} x_t y_t}{\sum_{t \in T_{\text{train}}} x_t^2}.$$

Con residuales $r_t^{(\text{tr})} = y_t - \hat{\alpha} x_t$ se calcularon

$$\text{SSE}_{\text{tr}} = \sum r_t^{(\text{tr})2}, \quad R_{0,\text{tr}}^2 = 1 - \frac{\text{SSE}_{\text{tr}}}{\sum_{t \in T_{\text{tr}}} y_t^2}, \quad \text{RMSE}_{\text{tr}} = \sqrt{\frac{1}{|T_{\text{tr}}|} \sum r_t^{(\text{tr})2}}.$$

Predicción y métricas en prueba. Sobre T_{test} se evaluó $\hat{y}_t = \hat{\alpha} x_t$ y los residuales $r_t^{(\text{te})} = y_t - \hat{y}_t$. Análogamente,

$$\text{SSE}_{\text{te}} = \sum r_t^{(\text{te})2}, \quad R_{0,\text{te}}^2 = 1 - \frac{\text{SSE}_{\text{te}}}{\sum_{t \in T_{\text{te}}} y_t^2}, \quad \text{RMSE}_{\text{te}} = \sqrt{\frac{1}{|T_{\text{te}}|} \sum r_t^{(\text{te})2}.$$

Tolerancia y alcance predictivo. Se consideró *predicción válida* cuando

$$|r_t^{(\text{te})}| \leq \tau_t, \quad \tau_t = \max(5 \mu\text{g}/\text{m}^3, 0,2 y_t), \quad t \in T_{\text{test}}.$$

A partir de ello se reportan: (i) **cobertura** (%) = $\frac{100}{|T_{\text{test}}|} \sum \mathbf{1}\{|r_t^{(\text{te})}| \leq \tau_t\}$; (ii) **rango válido** de x_t en prueba, $[x_{\min}^{(\text{te})}, x_{\max}^{(\text{te})}]$, restringido a los tiempos que cumplen la tolerancia; y (iii) el **bloque válido continuo más largo** en prueba, definido como la mayor sucesión de horas consecutivas dentro de T_{test} que satisfacen la condición de validez (la duración se informa en horas).

2.5. Tamaño mínimo de entrenamiento y alcance máximo

El objetivo es determinar, para cada estación de referencia, el **tamaño mínimo de entrenamiento** $m_{\min}$ (en horas/puntos) que permite aprender un modelo lineal forzado al origen $y = \alpha x$ con desempeño aceptable en *prueba*, y el **máximo alcance de predicción** (rango de x válido en prueba) bajo una tolerancia dada.

Implementación. Todo el procesamiento se implementó en Python (`pandas`, `numpy`, `matplotlib`). El **código exacto** se incluye como **Código 4** en los anexos del repositorio de esta entrega y reproduce: (i) lectura de CSV, remuestreo horario; (ii) promedios móviles *centrados* de $w = 72\text{h}$ con requisito $\geq 50\%$ de datos; (iii) construcción de pares comparables (x_t, y_t) ; (iv) barrido de tamaños de entrenamiento m y ajuste $y = \alpha x$ sin intercepto; (v) evaluación en prueba (segunda parte del conjunto); (vi) cálculo de cobertura, R_0^2 , RMSE y rango válido; (vii) selección de $m_{\min}$ y del modelo con *mejor alcance*.

Datos y preprocesamiento. A partir de los CSV (*Fecha*, *Hora*, *PM2.5*) se construyó la serie horaria por estación mediante promedio **por hora** y, sobre ésta, promedios móviles centrados de 72 h:

$$x_t = \text{roll}_{72\text{h}}^{\text{centro}}(\text{PM}_{2,5}^{(\text{bajo})}), \quad y_t = \text{roll}_{72\text{h}}^{\text{centro}}(\text{PM}_{2,5}^{(\text{ref})}).$$

Sea $T = \{t_1 < \dots < t_n\}$ el conjunto de tiempos donde ambos promedios están definidos (intersección temporal).

Modelo y ajuste. Para un tamaño de entrenamiento m (prefijo cronológico),

$$T_{\text{train}} = \{t_1, \dots, t_m\}, \quad T_{\text{test}} = \{t_{m+1}, \dots, t_n\}.$$

Se ajusta en entrenamiento el modelo $y_t = \alpha x_t$ con estimador de mínimos cuadrados (sin intercepto):

$$\hat{\alpha}(m) = \frac{\sum_{t \in T_{\text{train}}} x_t y_t}{\sum_{t \in T_{\text{train}}} x_t^2}.$$

En prueba se evalúan $\hat{y}_t = \hat{\alpha}(m) x_t$ y los residuales $r_t = y_t - \hat{y}_t$.

Tolerancia y métricas. La **tolerancia** se define como

$$|r_t| \leq \tau_t, \quad \tau_t = \max(5 \mu\text{g}/\text{m}^3, 0,2 y_t), \quad t \in T_{\text{test}}.$$

Se calcula en prueba: (i) la **cobertura** (%) de puntos que cumplen la tolerancia; (ii) el **coeficiente de determinación** del modelo sin intercepto,

$$R_{0,\text{test}}^2(m) = 1 - \frac{\sum r_t^2}{\sum_{t \in T_{\text{test}}} y_t^2},$$

(iii) la $\text{RMSE}_{\text{test}} = \sqrt{|T_{\text{test}}|^{-1} \sum r_t^2}$, y (iv) el **rango válido** de x en prueba, $[x_{\min}(m), x_{\max}(m)]$, restringido a los tiempos que cumplen la tolerancia.

Criterios de aceptación y búsqueda de $m_{\min}$. Se fijan umbrales de desempeño en prueba: cobertura $\geq \eta$ y $R_{0,\text{test}}^2 \geq \rho$. En esta entrega se usó $\eta = 95\%$ y $\rho = 0,95$. Se recorre un conjunto de tamaños m (prefijos cronológicos) desde un mínimo operativo $\max(100, 0,05 n)$ hasta $\lfloor n/2 \rfloor$ con paso de 100 puntos, incluyendo $\lfloor n/2 \rfloor$. Se define:

$$m_{\min} = \min\{m : \text{cobertura}(m) \geq \eta \wedge R_{0,\text{test}}^2(m) \geq \rho\}.$$

Alcance máximo de predicción. Entre los m que satisfacen los criterios, se selecciona el *mejor alcance* como aquel que maximiza la amplitud del rango válido de x en prueba:

$$m_{\text{mejor}} = \arg \max_m (x_{\max}(m) - x_{\min}(m)) \quad \text{sujeeto a} \quad \text{cobertura}(m) \geq \eta, \quad R_{0,\text{test}}^2(m) \geq \rho.$$

Se reportan, por estación: $m_{\min}$ y sus métricas asociadas $\{\hat{\alpha}(m_{\min}), R_{0,\text{test}}^2, \text{RMSE}_{\text{test}}, \text{cobertura}, [x_{\min}, x_{\max}]\}$, así como m_{mejor} y el rango válido $[x_{\min}, x_{\max}]_{\text{mejor}}$.

3. Resultados y análisis

3.1. Distancia Euclideana

En la Tabla 1 se reportan, para cada referencia y cada ancho de ventana w , el número de puntos comparables ($N = |T_w|$), la distancia euclídea $\mathcal{D}_w$ y el RMSE_w . La Figura 1 muestra la tendencia de RMSE_w con w .




Figura 1: RMSE entre promedios móviles de cada estación de referencia y la estación de bajo costo en función del ancho de ventana w .




Figura 2: Distancia euclídea agregada $\mathcal{D}_w$ entre los promedios móviles centrados de la estación de bajo costo y cada estación de referencia, para anchos de ventana $w \in \{3, 6, 12, 24, 48, 72\}$ h. La curva muestra una disminución monótona de $\mathcal{D}_w$ al aumentar w , con descensos pronunciados entre 3–24 h y rendimientos decrecientes a partir de 48 h. En todo el rango, Acualago exhibe las mayores distancias y Pilar las menores; el mínimo global se alcanza en $w = 72$ h para todas las estaciones.

Cuadro 1: Distancia euclídea $\mathcal{D}$ y RMSE entre promedios móviles de cada estación de referencia y la estación de bajo costo, para distintos anchos de ventana w (horas).

Estación	w (h)	N	$\mathcal{D}$	RMSE ($\mu\text{g}/\text{m}^3$)
Acualago	3	3844	490.587	7.912
Acualago	6	3819	452.007	7.313
Acualago	12	3814	419.375	6.791
Acualago	24	3834	398.179	6.431
Acualago	48	3839	385.137	6.216
Acualago	72	3884	381.214	6.117
Caldas	3	3822	423.120	6.846
Caldas	6	3796	377.290	6.119
Caldas	12	3791	339.018	5.507
Caldas	24	3811	317.728	5.148
Caldas	48	3839	308.082	4.972
Caldas	72	3884	304.801	4.891
Giron	3	3718	421.771	6.917
Giron	6	3720	365.036	5.987
Giron	12	3723	311.413	5.108
Giron	24	3725	265.821	4.354
Giron	48	3726	245.282	4.049
Giron	72	3726	241.485	3.956
Normal	3	3844	349.685	5.641
Normal	6	3839	294.792	4.759
Normal	12	3836	252.456	4.077
Normal	24	3834	230.687	3.728
Normal	48	3884	217.252	3.516
Normal	72	3884	214.688	3.445
Pilar	3	3401	325.695	5.576
Pilar	6	3401	278.043	4.769
Pilar	12	3401	235.303	4.034
Pilar	24	3401	206.527	3.541
Pilar	48	3401	196.451	3.368
Pilar	72	3401	189.654	3.252

3.2. Calibración lineal y alcance de validez

La calibración mediante el modelo forzado al origen $y = \alpha x$ sobre promedios móviles de $w = 72$ h arrojó ajustes consistentes con R_0^2 elevados en todas las estaciones de referencia y coberturas de validez $\geq 94\%$ salvo en el caso de Girón, donde la cobertura fue $\approx 93,9\%$. Los rangos de validez para x (bajo costo) se concentraron en $\sim 3,0\text{--}32,2 \mu\text{g}/\text{m}^3$ (Pilar hasta $\sim 31,5 \mu\text{g}/\text{m}^3$). Los coeficientes α evidencian una subestimación del bajo costo respecto a la referencia ($\alpha < 1$) con gradación por estación: Acualago ($\sim 0,64$) $<$ Caldas ($\sim 0,72$) $<$ Normal/Girón ($\sim 0,83$) $<$ Pilar ($\sim 0,92$).

Tabla principal. En la Tabla 2 se resumen, por estación, $\hat{\alpha}$ (IC95 %), R_0^2 , cobertura (%), rango x válido $[x_{\min}, x_{\max}]$ y el bloque válido continuo más largo (h). Inserte la tabla con:

Cuadro 2: Ajuste lineal forzado al origen $y = \alpha x$ entre referencia (y) y bajo costo (x) sobre promedios móviles de 72 h. Se reporta α con IC95 %, R^2 (modelo sin intercepto), cobertura de validez (tolerancia = $\max(5 \mu g/m^3, 0.2 y)$), rango de x válido y el bloque continuo válido más largo.

Ref.	N	α	IC95 % (inf)	IC95 % (sup)	R^2	Cobertura (%)	$x_{\min}$	$x_{\max}$	Bloque largo (h)
Acualago	3884	0.643512	0.640119	0.646905	0.972664	100.00	3.01	32.21	7230
Caldas	3884	0.719647	0.716488	0.722806	0.980898	100.00	3.01	32.21	7230
Giron	3726	0.830723	0.825428	0.836018	0.962105	93.85	3.09	32.21	3864
Normal	3884	0.828606	0.824802	0.832409	0.979149	100.00	3.01	32.21	7230
Pilar	3401	0.916634	0.910362	0.922907	0.960206	95.65	3.01	31.54	2331

Figuras de apoyo. Para cada estación se presentan tres visualizaciones complementarias: (i) dispersión y vs. x con recta $y = \hat{\alpha}x$ y línea 1:1, (ii) residuales vs. y con bandas de tolerancia $\pm \max(5, 0.2 \cdot y)$, y (iii) el histograma de residuales. A continuación se proveen los bloques figure para su inserción (use las rutas de los archivos .png descargados).




Figura 3: Acualago — (izq.) Dispersión con ajuste $y = \hat{\alpha}x$ y línea 1:1; (centro) residuales vs. y con bandas de tolerancia; (der.) histograma de residuales.




Figura 4: Caldas — (izq.) Dispersión; (centro) residuales con tolerancia; (der.) histograma.




Figura 5: Girón — (izq.) Dispersión; (centro) residuales con tolerancia; (der.) histograma.




Figura 6: Normal — (izq.) Dispersión; (centro) residuales con tolerancia; (der.) histograma.




Figura 7: Pilar — (izq.) Dispersión; (centro) residuales con tolerancia; (der.) histograma.

3.3. Validación por división mitad–mitad

La estrategia de dividir cronológicamente el conjunto alineado en *entrenamiento* (primera mitad) y *prueba* (segunda mitad) muestra que el modelo forzado al origen $y = \alpha x$ generaliza de forma consistente en todas las estaciones, con desempeños sobresalientes en **Caldas** y **Normal** (cobertura de tolerancia del 100 % y $R^2_{0,\text{test}} \geq 0,98$). En **Acualago** la cobertura es también muy alta (98.87 %) con $R^2_{0,\text{test}} \approx 0,96$. **Girón** y **Pilar** presentan coberturas menores (85.94 % y 81.31 %, respectivamente) y RMSE de prueba más altos, lo que sugiere revisar condiciones locales o considerar correcciones adicionales si se requiere una cobertura aún mayor.

Tabla principal. Los resultados cuantitativos completos (por estación) se presentan en la Tabla 3, que incluye α_{train} , R^2 y RMSE en entrenamiento y en prueba, además de la cobertura de tolerancia y el rango válido de x en la fase de prueba.

Cuadro 3: Calibración lineal con división mitad–mitad (entrenamiento en la primera mitad, prueba en la segunda) usando promedios móviles de 72 h. Se reporta α (entreno), R^2 y RMSE en entrenamiento y prueba, y la cobertura y rango válido de x en prueba.

Ref.	N_{train}	N_{test}	α_{train}	R^2_{train}	RMSE _{train}	R^2_{test}	RMSE _{test}	Cobertura (%)	$x_{\text{mín}}$ (test)	$x_{\text{máx}}$ (test)
Acualago	1942	1942	0.699520	0.970241	1.888	0.959905	2.099	98.87	10.43	28.36
Caldas	1942	1942	0.754280	0.976662	1.797	0.980481	1.691	100.00	10.43	29.18
Giron	1863	1863	0.889111	0.969572	2.524	0.944075	3.283	85.94	10.43	29.18
Normal	1942	1942	0.842033	0.965372	2.458	0.990461	1.394	100.00	10.43	29.18
Pilar	1700	1701	0.864336	0.960018	2.832	0.954652	3.316	81.31	6.06	27.54

Figuras de apoyo (fase de prueba). A continuación se incluyen, para cada estación, tres paneles: (i) dispersión y vs. x (solo prueba) con la recta $y = \hat{\alpha}x$ entrenada y la línea 1:1; (ii) residuales vs. y con bandas de tolerancia $\pm \text{máx}(5, 0.2y)$; (iii) histograma de residuales. Sustituya las rutas por las de sus archivos descargados si es necesario.




Figura 8: Acualago (prueba) — Dispersión con ajuste (izq.), residuales con tolerancia (centro) e histograma de residuales (der.).




Figura 9: Caldas (prueba) — Dispersión, residuales con tolerancia e histograma.




Figura 10: Girón (prueba) — Dispersión, residuales con tolerancia e histograma.




Figura 11: Normal (prueba) — Dispersion, residuales con tolerancia e histograma.




Figura 12: Pilar (prueba) — Dispersion, residuales con tolerancia e histograma.

3.4. Tamaño mínimo de entrenamiento y alcance máximo

Para cada estación de referencia se exploraron prefijos cronológicos de tamaño m (en horas/puntos) sobre las series suavizadas con promedios móviles *centrados* de $w = 72$ h. El objetivo fue hallar (i) el **tamaño mínimo de entrenamiento** $m_{\min}$ tal que, en *prueba* (el sufijo temporal restante), se cumplan simultáneamente los criterios:

$$\text{Cobertura} \geq 95\% \quad \text{bajo la tolerancia} \quad |y - \alpha x| \leq \max(5 \mu\text{g}/\text{m}^3, 0.2y), \quad \text{y} \quad R_{0,\text{test}}^2 \geq 0.95,$$

y (ii) el **máximo alcance de predicción**, entendido como el mayor rango de x válido en prueba $[x_{\min}, x_{\max}]$ entre los modelos que satisfacen dichos umbrales.

Tabla principal. La [Tabla 4](#) resume, por estación, N_{total} , el mínimo $m_{\min}$ con sus métricas asociadas $\{\hat{\alpha}(m_{\min}), R_{0,\text{test}}^2, \text{RMSE}_{\text{test}}, \text{cobertura}, [x_{\min}, x_{\max}]\}$, y el m que logra el *mejor alcance* (mayor amplitud $x_{\max} - x_{\min}$) sujeto a los mismos criterios. Inserte la tabla con:

Cuadro 4: Mínimo tamaño de entrenamiento $m_{\min}$ para alcanzar cobertura $\geq 95\%$ y $R_{\text{test}}^2 \geq 0,95$, y máximo alcance de predicción (rango válido de x en prueba) para la tolerancia $|y - \alpha x| \leq \max(5, 0,2y)$. *Nota:* “—” indica que no se encontró m que cumpla simultáneamente ambos umbrales.

Ref.	N_{total}	$m_{\min}$	$\alpha@m_{\min}$	$R_{\text{test}}^2@m_{\min}$	$\text{RMSE}_{\text{test}}@m_{\min}$	Cobertura@min (%)	$x_{\min}@m_{\min}$	$x_{\max}@m_{\min}$	$m_{\text{mejor_alcance}}$	$[x_{\min}, x_{\max}]_{\text{mejor}}$
Acualago	3884	494	0.710611	0.955870	2.132	98.91	3.01	30.68	494	[3.01, 30.68]
Caldas	3884	194	0.768117	0.976904	1.829	99.97	3.01	32.21	194	[3.01, 32.21]
Giron	3726	—	—	—	—	—	—	—	—	—
Normal	3884	194	0.803626	0.978356	2.047	100.00	3.01	32.21	194	[3.01, 32.21]
Pilar	3401	—	—	—	—	—	—	—	—	—

Síntesis por estación.

- **Acualago:** $m_{\min} = 494$ h ($\sim 20,6$ días). En $m_{\min}$: $\hat{\alpha} = 0,710611$, $R_{0,\text{test}}^2 = 0,955870$, $\text{RMSE}_{\text{test}} = 2,132 \mu\text{g}/\text{m}^3$, cobertura 98,91 %, rango válido [3,01, 30,68] $\mu\text{g}/\text{m}^3$. El *mejor alcance* coincide en $m = 494$ h.
- **Caldas:** $m_{\min} = 194$ h ($\sim 8,1$ días). En $m_{\min}$: $\hat{\alpha} = 0,768117$, $R_{0,\text{test}}^2 = 0,976904$, $\text{RMSE}_{\text{test}} = 1,829 \mu\text{g}/\text{m}^3$, cobertura 99,97 %, rango válido [3,01, 32,21] $\mu\text{g}/\text{m}^3$. *Mejor alcance* también en $m = 194$ h.
- **Normal:** $m_{\min} = 194$ h ($\sim 8,1$ días). En $m_{\min}$: $\hat{\alpha} = 0,803626$, $R_{0,\text{test}}^2 = 0,978356$, $\text{RMSE}_{\text{test}} = 2,047 \mu\text{g}/\text{m}^3$, cobertura 100,00 %, rango válido [3,01, 32,21] $\mu\text{g}/\text{m}^3$. *Mejor alcance* en $m = 194$ h.
- **Girón:** no se logró cobertura $\geq 95\%$ junto con $R_{0,\text{test}}^2 \geq 0,95$ en el rango explorado. El mejor compromiso (máxima cobertura) apareció en $m = 586$ h: cobertura 93,47 %, $R_{0,\text{test}}^2 = 0,9570$, rango válido [3,01, 29,18] $\mu\text{g}/\text{m}^3$.
- **Pilar:** tampoco se alcanzaron simultáneamente ambos umbrales. Mejor compromiso en $m = 3070$ h: cobertura 88,52 %, $R_{0,\text{test}}^2 = 0,9552$, rango válido [12,29, 27,54] $\mu\text{g}/\text{m}^3$.

Figuras. A continuación se muestran, para cada estación, las dos curvas clave del barrido: (i) *cobertura* en prueba (%) vs. tamaño de entrenamiento m , y (ii) $[x_{\min}, x_{\max}]$ válido en prueba vs. m . Estas figuras permiten identificar visualmente $m_{\min}$ (primer cruce de umbrales) y el m con *mejor alcance*.




Figura 13: Acualago — (izq.) Cobertura en prueba (%) vs. m ; (der.) rango válido de x en prueba $[x_{\min}, x_{\max}]$. Tolerancia: $|y - \alpha x| \leq \max(5, 0.2y)$.




Figura 14: Caldas — (izq.) Cobertura en prueba vs. m ; (der.) rango válido de x en prueba. Tolerancia: $|y - \alpha x| \leq \max(5, 0.2y)$.




Figura 15: Girón — (izq.) Cobertura en prueba vs. m ; (der.) rango válido de x en prueba. Tolerancia: $|y - \alpha x| \leq \max(5, 0.2y)$.




Figura 16: Normal — (izq.) Cobertura en prueba vs. m ; (der.) rango válido de x en prueba. Tolerancia: $|y - \alpha x| \leq \max(5, 0.2y)$.




Figura 17: Pilar — (izq.) Cobertura en prueba vs. m ; (der.) rango válido de x en prueba. Tolerancia: $|y - \alpha x| \leq \max(5, 0.2y)$.

4. Conclusiones y Recomendaciones

El principal aporte de este trabajo radica en haber establecido un marco metodológico robusto para la calibración inteligente de sensores de bajo costo mediante mínimos cuadrados, demostrando que es posible alcanzar precisiones comparables a estaciones de referencia con una fracción del costo.

Interpretación de los resultados. Los coeficientes de calibración α entre 0,64–0,92 obtenidos reflejan diferencias sistemáticas entre sensores que pueden corregirse efectivamente. La ventana óptima de 72 horas sugiere que la suavización temporal juega un papel crucial en la estabilización de las mediciones. La validación exitosa en Caldas y Normal (100 % cobertura) confirma la generalización del método, mientras que los casos de Girón y Pilar indican la necesidad de considerar factores locales adicionales.

Trascendencia de los hallazgos. Este trabajo trasciende el ámbito técnico al proveer una solución escalable para el monitoreo ambiental accesible. La determinación de tamaños mínimos de entrenamiento (194–494 horas) establece parámetros prácticos para implementaciones reales, potentially revolucionando el despliegue de redes de sensores en países en desarrollo.

Recomendaciones específicas. Para futuras implementaciones: (i) utilizar períodos de calibración inicial de 3–4 semanas; (ii) priorizar el modelo lineal forzado al origen por su simplicidad y efectividad; (iii) establecer protocolos de validación continua cada 6 meses; (iv) explorar la incorporación de variables meteorológicas para mejorar el desempeño en ubicaciones problemáticas.

La metodología aquí presentada sienta las bases para una nueva generación de sistemas de monitoreo ambiental democratizados, donde la precisión no esté reñida con la accesibilidad económica.

5. Referencias

Referencias

- [1] Gauss, K. F. (1809). *Theoria Motus Corporum Coelestium in Sectionibus Conicis Solem Ambientium*. Hamburg: Perthes et Besser.
- [2] Legendre, A. M. (1805). *Nouvelles méthodes pour la détermination des orbites des comètes*. Paris: Courcier.
- [3] Box, G. E. P., Hunter, W. G., & Hunter, J. S. (1976). *Statistics for Experimenters: An Introduction to Design, Data Analysis, and Model Building*. John Wiley & Sons.
- [4] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis* (5th ed.). Wiley.
- [5] Zheng, Y., Liu, F., & Hsieh, H. P. (2014). U-Air: When urban air quality inference meets big data. In *Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining* (pp. 1436-1444).
- [6] Snyder, E. G., Watkins, T. H., Solomon, P. A., Thoma, E. D., Williams, R. W., Hagler, G. S., ... & Preuss, P. W. (2013). The changing paradigm of air pollution monitoring. *Environmental Science & Technology*, 47(20), 11369-11377.
- [7] Kumar, P., Morawska, L., Martani, C., Biskos, G., Neophytou, M., Di Sabatino, S., ... & Britter, R. (2015). The rise of low-cost sensing for managing air pollution in cities. *Environment International*, 75, 199-205.
- [8] Hasenfratz, D., Saukh, O., & Thiele, L. (2012). On-the-fly calibration of low-cost gas sensors. In *Wireless Sensor Networks* (pp. 228-244). Springer, Berlin, Heidelberg.
- [9] Spinelle, L., Gerboles, M., Villani, M. G., Aleixandre, M., & Bonavitacola, F. (2015). Field calibration of a cluster of low-cost available sensors for air quality monitoring. Part A: Ozone and nitrogen dioxide. *Sensors and Actuators B: Chemical*, 215, 249-257.
- [10] United States Environmental Protection Agency. (2016). *Air Sensor Guidebook*. EPA/600/R-14/159.
- [11] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [12] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- [13] Van Rossum, G., & Drake, F. L. (2020). *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace.
- [14] McKinney, W. (2010). Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference* (pp. 51-56).

- [15] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.